

Exercice

Un chercheur entraîne plusieurs modèles de régression de polynômes avec degré $\dots 1, \dots, M$.

Il y a 40 observations $\{(x_i, y_i)\}_{i=1}^{40}$

Sélection du degré du polynôme par validation croisée à 5 replis: $m^* = 9$

(a) le modèle avec $m^* = 9$ s'ajuste presque parfaitement aux données mais la performance en test est faible.

expliquez dans vos mots pourquoi un modèle avec une faible erreur d'entraînement ne réussit pas généraliser.

Réponse: trop faible d'entraînement

CV=5 risque de sur-ajuster les données

(b) ajout de régularisation L_2 : régression ridge.

Tracez à main levée le comportement de l'erreur d'entraînement et de validation en fonction de λ .

2) Identifiez les régions sous-app, optimal, sur-apprentissage.

(c) les mesures proviennent en fait de deux sites aux propriétés très différentes. Le chercheur utilise un seul modèle sur les 40 observations.

En utilisant les notions de distribution de probabilité

vous en cours, expliquez pourquoi cela peut nuire à la performance du modèle et suggérez une solution.

2) 200 mesures journalières sédiments en suspension d'une rivière

⇒ les données semblent unimodales

⇒ la distribution est asymétrique vers la droite.

a) On ajuste une gaussienne par max de vraisemblance.

⇒ Expliquez pourquoi et comment la présence d'un petit nombre d'événements extrêmes affecte l'estimation de la variance

⇒ Quelles sont les conséquences pratiques si on cherche à estimer les proba des valeurs typiques.

(b) alternatives :- t de Student

- Mélanges de gaussiennes à 5 composantes

Expliquez lequel des 3 modèles vous choisissez et pourquoi.

i) Comment le modèle correspond ou pas à ce que vous connaissez des données.

ii) le risque de sur-ajustement étant donné la taille d'entraînement.

iii) La facilité à bien ajuster chaque modèle.

Partie II

Classification des mesures d'écoulement d'une rivière
(sous critique, sur-critique)

Données d'entrées : vitesse de l'écoulement v
: Profondeur de l'eau d

300 observations : 270 sous critique
= 30 sur-critique

Performance du modèle :

95% (entraînement)

61% (en test)

(a) Donnez 2 explications différentes pour expliquer la différence de performance entre l'entraînement et le test.

- i) Décrivez le mécanisme causant cette différence
- ii) Commentez sur l'interprétation des mesures de performance.

(iii) Proposez un diagnostic pour vérifier quelle explication est en cause.

Réponses

i)

(1) = Déséquilibre de classes

(2) = Sur-apprentissage

ii)

- iii) ① : cours les d'erreur entraînement et test.
② vérifier les proportion de chaque classe prédite en test.

(b) Nombre de fraude $Fr = \frac{v}{\sqrt{9d}}$

on utilise le classifieur : régression logistique.

→ Expliquez en quoi ce modèle est mal adapté pour faire la classification dans (v, d)

Réponse :

on sait que la régression logistique est un classifieur linéaire.

Il est mal adapté car Fr est non-linéaire.

Solutions :

- classifieur par rapport à Fr
- classifieur par rapport à $(v, \sqrt{9d})$

Bishop: B.4.9.

classifieur probabiliste pour K classes.

$P(C_k) = \pi_k$ - Proba a priori

$P(\phi/C_k)$ - Proba conditionnelle de classe

ϕ : vecteur de caractéristiques

$\{(\phi_n, t_n)\}_{n=1}^N$: $1 \leq n \leq N$, indépendantes

$\{0, 1\}$: encodage sur K . Si je suis dans la classe k , $t_n = 1$ et si je suis $\bar{k}$, $t_n = 0$.

Montrez que les estimateurs par maximum de vraisemblance de π_k est $\hat{\pi}_k = N_k / N$

Réponse

Vraisemblance (loi multinomiale)
on a K classes

$$P(X = (k_1, k_2, \dots, k_N)) = \prod_{i=1}^N p_i^{k_i}$$

Probabilité d'une observation $P(\phi_n, t_n)$

$$P(\phi_n, t_n) = \prod_{i=1}^K P(\phi_n, C_i)^{t_{ni}}$$

La

La vraisemblance est donnée par :

$$\prod_{n=1}^N \prod_{i=1}^K P(\Phi_n, c_i)^{t_{ni}}$$

on prend $\ln$

on obtient :

$$= \sum_{n=1}^N \sum_{i=1}^K t_{ni} \cdot \ln P(\Phi_n, c_i)$$

$$= \sum \sum t_{ni} \ln [P(\Phi_n / c_i) \cdot P(c_i)]$$

Multiplieur de Lagrange : $\sum_{i=1}^K \pi_i = 1$

$$\sum_{n=1}^N \sum_{i=1}^K t_{ni} (\ln P(\Phi_n / c_i) + \ln \pi_i) + \lambda \left(\sum_{i=1}^K \pi_i - 1 \right)$$

dérivées par rapport à π_k