

SYNTHÈSE POUR L'EXAMEN

MTH8304 — Apprentissage non-supervisé et séries chronologiques

Cours de Julie Carreau · Polytechnique Montréal

MODULE 1 — K plus proches voisins (KNN)

Principe

Étant donné x^* , trouver les K voisins les plus proches dans l'ensemble d'entraînement et attribuer la **classe majoritaire**.

$$j^* = \underset{j}{\operatorname{argmin}} d(x_j, x^*) \text{ où } d(x_j, x_k) = \sqrt{\sum_i (x_{j,i} - x_{k,i})^2}$$

Effet de K :

K petit	K grand
Faible biais, forte variance	Fort biais, faible variance
Frontières irrégulières (sur-apprentissage)	Frontières lisses (sous-apprentissage)

MODULE 2 — Régression logistique + Ré-échantillonnage

Régression logistique — 2 classes

$$P(C=1|x) = \sigma(w^T \phi(x)) = 1 / (1 + \exp(-w^T \phi(x)))$$

$$\text{Entropie croisée : } E(w) = - \sum_n \{ t_n \ln(y(x_n)) + (1-t_n) \ln(1-y(x_n)) \}$$

$$\text{Gradient : } \nabla E(w) = \sum_n (y(x_n) - t_n) \phi(x_n) \rightarrow \text{pas de solution analytique}$$

K classes → Softmax :

$$P(C=k|x) = \exp(w_k^T \phi(x)) / \sum_j \exp(w_j^T \phi(x))$$

Validation croisée

Méthode	Biais	Variance	Coût
Validation simple	Élevé	Faible	Faible
K-folds (K=5 ou 10)	Intermédiaire	Intermédiaire	Moyen
LOO (K=N)	Très faible	Élevée (modèles corrélés)	Élevé

Bootstrap

Tirer N exemples **avec remise** parmi N données → ~36.8% des données ne sont PAS tirées.

But : estimer la **variabilité/incertitude** d'un estimateur.

MODULE 3 — Loi normale multivariée & LDA/QDA

$$p(x|\mu, \Sigma) = (2\pi)^{-D/2} |\Sigma|^{-1/2} \exp(-\frac{1}{2} (x-\mu)^T \Sigma^{-1} (x-\mu))$$

LDA vs QDA

	LDA	QDA
Covariance	Commune Σ à toutes les classes	Différente Σ_k par classe
Frontière	Linéaire	Quadratique
Nb paramètres	Moins ($\downarrow$ variance)	Plus ($\downarrow$ biais)
Préférable si	Peu de données	Beaucoup de données

Règle de Bayes : $P(C_k|x) \propto P(x|C_k) P(C_k)$

MODULE 5 — Clustering (Classification non-supervisée)

■ TRÈS IMPORTANT : K-moyennes

K-moyennes (K-means) — Minimisation de :

$$J = \sum_n \sum_k r_{nk} \|x_n - \mu_k\|^2$$

Algorithme EM itératif :

- **Initialisation** : choisir K centres μ_k (tirage aléatoire d'exemples)
- **E-step** : $r_{nk} = 1$ si $k = \text{argmin}_k \|x_n - \mu_k\|^2$ (affecter au centre le plus proche)
- **M-step** : $\mu_k = (\sum_n r_{nk} x_n) / (\sum_n r_{nk})$ (recalculer les centres = moyennes)
- Répéter jusqu'à convergence (J ne peut que $\downarrow$).

Points clés :

- Convergence garantie mais vers un **minimum local** $\rightarrow$ relancer plusieurs fois
- Sensible à l'initialisation et aux **outliers**
- K doit être fixé à l'avance $\rightarrow$ méthode du coude sur J

K-médoïdes

Prototype = un point réel des données. Plus robuste aux outliers. Basé sur des **dissimilarités** (pas forcément euclidiennes).

Clustering hiérarchique

- **Agglomératif (bottom-up)** : partir de N singletons, fusionner les plus proches $\rightarrow$ dendrogramme
- Liens : single, complete, average, Ward
- Choix de K : couper le dendrogramme au bon niveau

MODULE 6 — Mélange de gaussiennes + Algorithme EM

■ TRÈS IMPORTANT : Savoir interpréter une sortie mclust (R)

KDE (Kernel Density Estimation)

$$p_{\text{KDE}}(x) = (1/N) \sum_n (1/\sqrt{2\pi}h) \exp(-\|x-x_n\|^2 / 2h^2)$$

h = paramètre de lissage : petit h $\rightarrow$ variance élevée ; grand h $\rightarrow$ biais élevé.

Mélange de gaussiennes

$$p_{\text{MG}}(x) = \sum_k \pi_k N(x; \mu_k, \Sigma_k) \text{ avec } \pi_k \geq 0 \text{ et } \sum_k \pi_k = 1$$

$$\text{Variable latente } z : P(z=k) = \pi_k \text{ (classe cachée non observée)}$$

$$\text{Responsabilité : } \gamma(z_k) = P(z_k=1|x) = \pi_k N(x; \mu_k, \Sigma_k) / \sum_j \pi_j N(x; \mu_j, \Sigma_j)$$

$\rightarrow$ Clustering **soft** : attribuer la classe k si $\gamma(z_k) \geq \gamma(z_j)$ pour tout $j \neq k$.

Algorithme EM pour le mélange de gaussiennes :

Étape	Formule
E-step	Calculer $\gamma(z_{nk})$ pour chaque point x_n
M-step : μ_k	$\mu_k = (1/N_k) \sum_n \gamma(z_{nk}) x_n$ avec $N_k = \sum_n \gamma(z_{nk})$
M-step : Σ_k	$\Sigma_k = (1/N_k) \sum_n \gamma(z_{nk}) (x_n - \mu_k)(x_n - \mu_k)^T$
M-step : π_k	$\pi_k = N_k / N$

Analogie avec K-means : EM = K-means mou (remplacer $r_{nk} \in \{0,1\}$ par $\gamma(z_{nk}) \in [0,1]$).

Choix de K et type Σ_k : critère BIC — plus bas (en valeur abs.) = meilleur modèle.

Singularités : risque si une composante converge vers un seul point $\rightarrow \sigma_k \rightarrow 0$.

Lire une sortie R (mclust) :

- **Mixing probabilities** = π_k (proportion de chaque composante)
- **Means** = μ_k (centre de chaque groupe)
- **BIC** : comparer les modèles (plus élevé en valeur absolue = moins bon)
- **VVV** = matrices de covariance flexibles (Volume, Variance, Orientation variables)

MODULE 7 — Séries chronologiques : Analyses préliminaires

Composantes d'une série temporelle

Modèle	Formule	Quand ?
Additif	$X_t = T_t + S_t + I_t$	Amplitude saisonnière constante
Multiplicatif	$X_t = T_t \times S_t \times I_t$	Amplitude saisonnière croissante
Transformation	$\log(X_t) \rightarrow$ additif	Pour ramener au cas additif

Fonction d'auto-corrélation (ACF)

$$r_k = \sum_t (x_{t-k} - \bar{x})(x_t - \bar{x}) / \sum_t (x_t - \bar{x})^2$$

Pattern ACF	Interprétation
≈ 0 partout	Bruit blanc
Décroissance lente	Tendance présente
Pics à $k = m, 2m, 3m, \dots$	Saisonnalité de période m

Transformation de Box-Cox

$$x'_t = (x_t^\lambda - 1)/\lambda \text{ si } \lambda \neq 0, \ln(x_t) \text{ si } \lambda = 0 \rightarrow \text{stabilise la variance}$$

MODULE 8 — Lissage exponentiel & Méthodes de référence

Méthode	Formule
Moyenne	$x_{T+h} = \bar{x}$
Naïve simple	$x_{T+h} = x_T$ (= marche aléatoire)
Naïve saisonnière	$x_{T+h} = x_{T+h-m}$

Diagnostics des résidus

Bons résidus : moyenne ≈ 0 , **non corrélés**, variance constante, distribution normale.

Test de Ljung-Box :

$$Q^* = T(T+2) \sum_{k=1}^K (T-k)^{-1} r_k^2 \sim \chi^2(K) \text{ sous } H_0 \text{ (non-corrélation)}$$

Si valeur-p > 0.05 : on ne rejette pas H_0 → résidus non corrélés → modèle acceptable.

Intervalle de prévision :

$$x_{t+h}|T \pm 1.96 \sigma_{t+h} \text{ (}\sigma_{t+h} \text{ augmente avec } h \rightarrow \text{incertitude croissante)}$$

MODULE 9 — Modèles ARIMA

LE PLUS IMPORTANT DE L'EXAMEN

Stationnarité

Définition : $\mu(t)$ = constante et $\gamma(t+h,t)$ ne dépend pas de t .

Graphiquement : série oscillant autour d'une ligne horizontale avec écart-type constant.

Rendre une série stationnaire :

- **Différence d'ordre 1** : $\nabla X_t = X_t - X_{t-1}$ (enlève la tendance linéaire)
- **Différence saisonnière** : $\nabla_m X_t = X_t - X_{t-m}$ (enlève la saisonnalité)
- **Test KPSS** : valeur-p < 0.05 → non-stationnaire → appliquer une différence

Processus de base et identification par ACF/PACF

RÈGLE CLÉ : AR(p) → PACF coupe à p | MA(q) → ACF coupe à q

Processus	Formule	ACF	PACF
Bruit blanc	$X_t = Z_t$	≈ 0 partout	≈ 0 partout
AR(p)	$X_t = c + \sum \phi_i X_{t-i} + Z_t$	Décroissance exponentielle	Coupe après lag p ✓
MA(q)	$X_t = c + Z_t + \sum \theta_i Z_{t-i}$	Coupe après lag q ✓	Décroissance exponentielle
ARMA(p,q)	Combinaison AR+MA	Décroissance lente	Décroissance lente

Processus ARIMA(p, d, q)

- Appliquer **d fois** l'opérateur ∇ pour rendre la série stationnaire, puis ajuster ARMA(p,q)
- ARIMA(0,0,0) = bruit blanc | ARIMA(0,1,0) = marche aléatoire

Comportement des prévisions selon d (avec c=0) :

d	c = 0	c ≠ 0
0	Prévisions → 0	Prévisions → moyenne des données
1	Prévisions → constante	Prévisions → droite
2	Prévisions → droite	Prévisions → tendance quadratique

Sélection des ordres — Critères d'information

$$AIC = -2 \ln(L) + 2(p+q+k+1)$$

$$AIC_c = AIC + 2(p+q+k+1)(p+q+k+2) / (T-p-q-k-2) \text{ [privilégié dans ce cours]}$$

$$BIC = AIC + (\ln(T)-2)(p+q+k+1)$$

→ Des valeurs plus faibles indiquent un meilleur modèle.

Étapes de modélisation ARIMA

Étape	Action	Outil
1	Graphique temporel	Détecter tendance, saisonnalité

Étape	Action	Outil
2	Transformation Box-Cox	Stabiliser la variance (si nécessaire)
3	Différenciation (choisir d)	Test KPSS + graphique ACF
4	Identifier p et q	ACF → MA(q), PACF → AR(p)
5	Ajustement des modèles	AICc (plusieurs modèles candidats)
6	Analyse des résidus	Test Ljung-Box (non-corrélation)
7	Prévision	Intervalle de prévision bootstrap si non-normal

ARIMA Saisonnier : SARIMA(p,d,q)(P,D,Q)m

- m = période saisonnière (ex: m=12 pour données mensuelles)
- D = différences saisonnières ($\nabla^D X_t$)
- P et Q : identifier dans ACF/PACF aux lags m, 2m, 3m...

RÉCAPITULATIF — Questions typiques à l'examen

Thème	Questions typiques
K-means / EM	Décrire les étapes E et M, analyser convergence, interpréter responsabilités
Mélange de gaussiennes	Lire sortie R (mclust) : interpréter π_k , μ_k , Σ_k , BIC
ACF / PACF	Identifier AR(p) vs MA(q) vs ARMA vs bruit blanc à partir d'un graphique
Stationnarité	Identifier si une série est stationnaire et quelle transformation appliquer
ARIMA	Identifier (p,d,q) à partir d'ACF/PACF, interpréter sortie R, calculer prévision
Résidus	Interpréter un test de Ljung-Box, diagnostiquer les résidus d'un modèle
Validation croisée	Comparer LOO vs K-folds (biais/variance), utilité du bootstrap
BIC	Comparer des modèles, choisir K dans un mélange de gaussiennes

Bonne chance pour l'examen ! ■